# نظم استرجاع المعلومات **Information Retrieval System** مقدمة Introduction Afaf Al shalaby, PH.D

## مخطط العرض PLAN

- الهدف من مقرر نظم استرجاع المعلومات (IR) Information Retrieval System
  - تطبيقات نظم استرجاع المعلومات
  - ما هي نظم استرجاع المعلومات؟
  - تنظيم المقرر الدراسي Course Organization
    - خارطة الطريق لليوم Today's Roadmap
      - التحديات Challenges

## الهدف من المقرر Goals



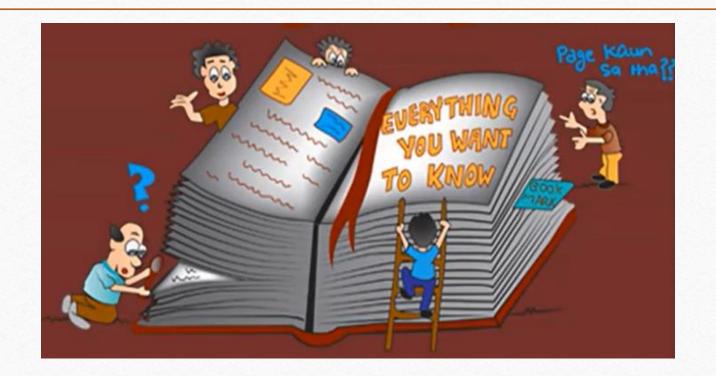
- تعلم المبادئ الأساسية في نظم استرجاع المعلومات.
- التعرف على الأدوات المستعملة لبناء نظم استرجاع معلومات من خلال جلسات العملي

## الهدف من المقرر

Search Engines changed the world!



# الهدف من المقرر





- تتيح لنا محركات البحث، البحث عن المعلومات بشكل آلي.
  - سرعة في البحث
  - جودة في المصادر
  - تخفيض الكلفة في البحث
  - إتاحة الوصول لمعلومات كبيرة جدا

## الهدف من المقرر

Search Engines changed the world!

IR is the field that changed the world!

• نظم استرجاع المعلومات هي التقنية أو العلم ما وراء محركات البحث

## مخطط العرض PLAN

- الهدف من المقرر
- تطبيقات نظم استرجاع المعلومات
- ما هي نظم استرجاع المعلومات؟
- تنظيم المقرر الدراسي Course Organization
  - خارطة الطريق لليوم Today's Roadmap
    - التحديات Challenges

## تطبيقات نظم استرجاع المعلومات



#### • ما هي IRS؟

- ما هي تطبيقات نظم استرجاع المعلومات الموجودة في حياتنا اليومية؟
- استرجاع المعلومات هو ليس فقط جوجل

IR is **NOT** just the search box!

• ليس مجرد البحث النصي في غوغل.



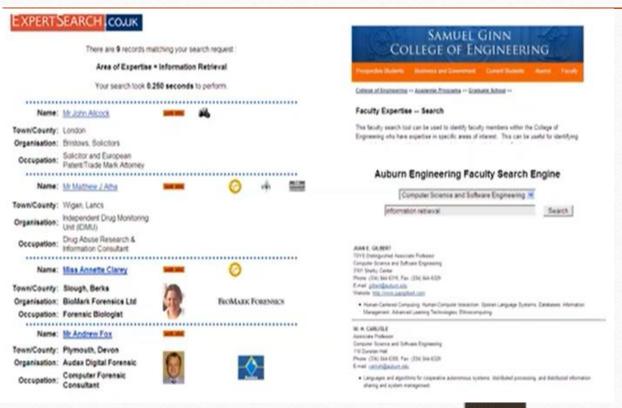


#### :microblog search: •

- البحث في المدونات الصغيرة
- كالبحث في وسائل التواصل الاجتماعي



- Text :classification
- التصنيف الآلي للنصوص



- :Expert Search •
- البحث عن أشخاص (ليس وثائق) خبراء في مجال معين وفي مجتمع معين وبثقه عالية











• Speech Search: البحث عن مقاطع صوتية وليس نصوص





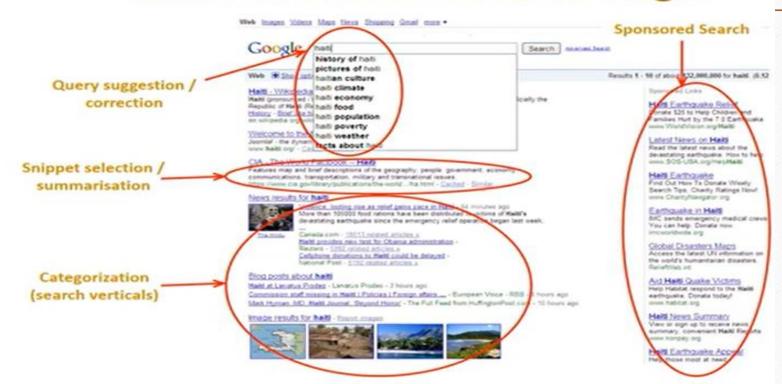
• Conversational: الإجابة الآلية عن Search: المستخدم في نظم التحاور الآلي

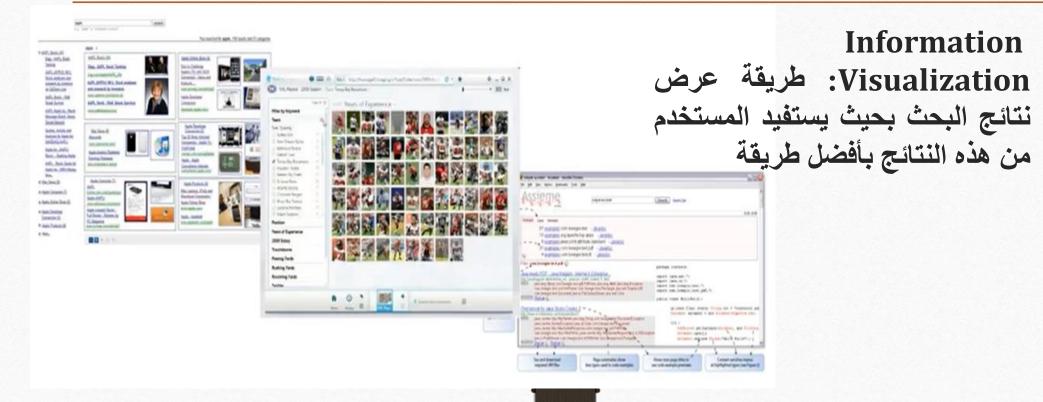


#### **Recommendation** •

: التوصيات سواء التتبع للأشخاص أو التوصيات ببعض المنتجات

#### **Stuff on Search Results Page!**





Information

## مخطط العرض PLAN

- الهدف من المقرر
- تطبيقات نظم استرجاع المعلومات
- ما هي نظم استرجاع المعلومات؟
- تنظيم المقرر الدراسي Course Organization
  - خارطة الطريق لليوم Today's Roadmap
    - التحديات Challenges

# ما هي نظم استرجاع المعلومات؟

• هي التقنية أو العلم الذي يربط الناس بالمعلومات

IR is about technology to connect people to information

# ما هي نظم استرجاع المعلومات؟



## مخطط العرض PLAN

- الهدف من المقرر
- تطبيقات نظم استرجاع المعلومات
- ما هي نظم استرجاع المعلومات؟
- تنظيم المقرر الدراسي Course Organization
  - خارطة الطريق لليوم Today's Roadmap
    - التحديات Challenges

# تنظيم المقرر الدراسي Course Organization

- Duration & Daily Schedule
  - 3 "intensive" months!
  - Every Sunday from today (Sunday October 14th) to Sunday January 15<sup>th</sup>

Time	Activity
On Sunday 8:00 am-9:30 am	Lecture Part 1
On Sunday 11:00 am-12:30 pm	Lecture Part 1
On Sunday 9:30 am-11:00 am	Practical Session



## المصادر Resources

- Lecture slides
- Readings
  - Introduction to Information Retrieval, by C. Manning, P. Raghavan, and H. Schütze, 2008.
  - Search Engines: Information Retrieval in Practice, by W. Bruce Croft, D. Metzler, and T. Strohman, 2010.
  - An introduction to Neural Information Retrieval, by Bhaskar Mitra and Nick Craswell, 2018.
  - Pretrained Transformers for Text Ranking: BERT and Beyond, by Jimmy Lin, Rodrigo Nogueira, and Andrew Yates, 2020.
- Lab notebooks

# المتطلبات المسبقة Prerequisites

- No prior knowledge of IR is required.
- At least, undergrad-level courses
  - Programming (Python)
  - Data structures or Algorithms
  - Basic Probability theory
  - Basic Linear algebra

## مخطط العرض PLAN

- الهدف من المقرر
- تطبيقات نظم استرجاع المعلومات
- ما هي نظم استرجاع المعلومات؟
- تنظيم المقرر الدراسي Course Organization
  - خارطة الطريق لليوم Today's Roadmap
    - التحديات Challenges

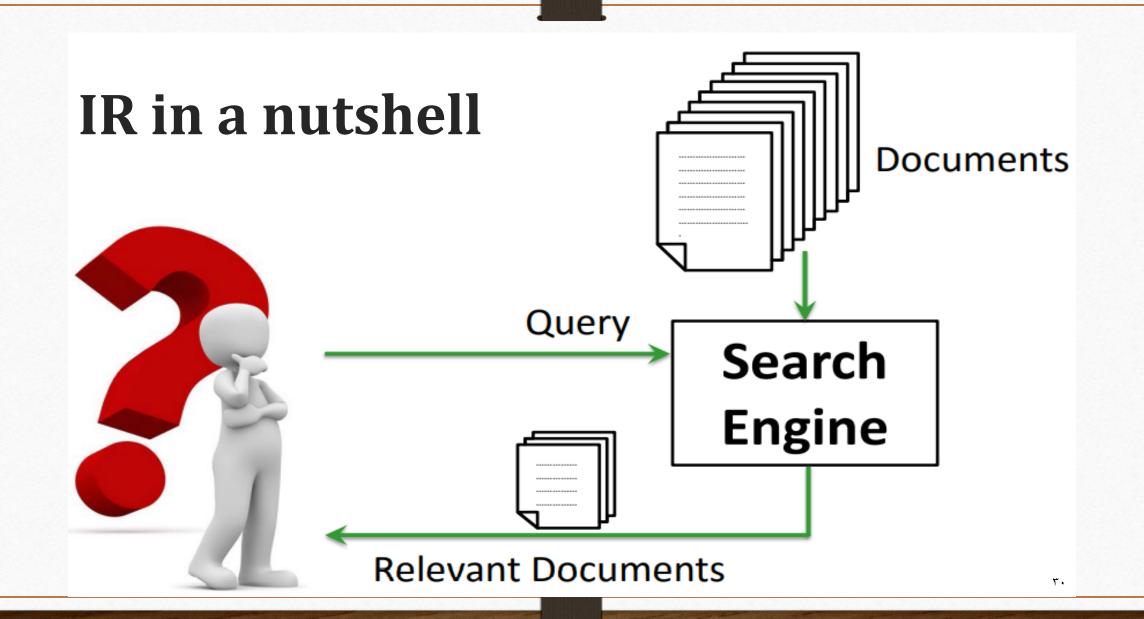
# خارطة الطريق لليوم Today's Roadmap

- Introduction to IR
- How IR "sees" documents?
- Boolean retrieval

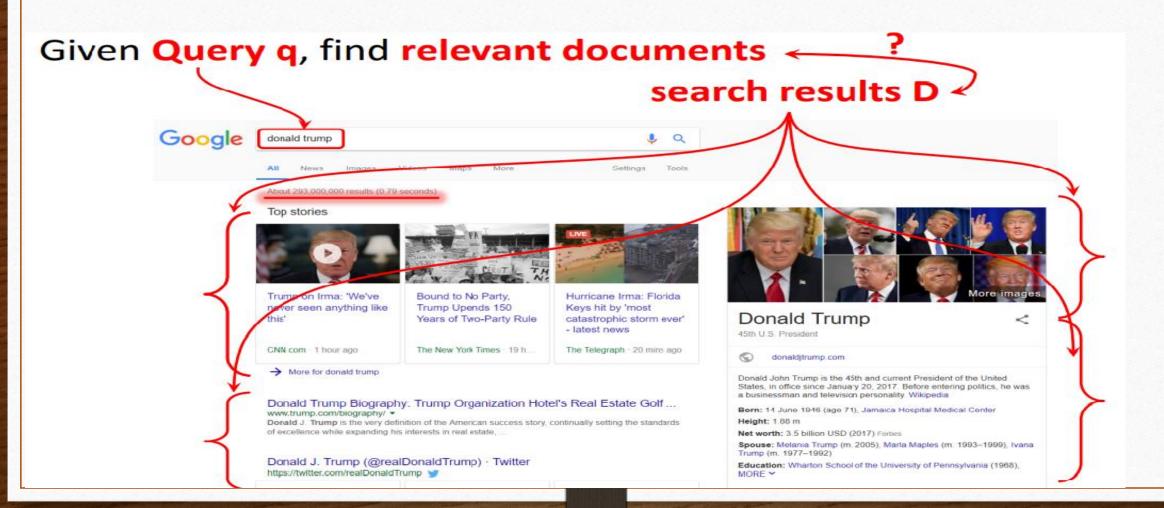


## Introduction to IR





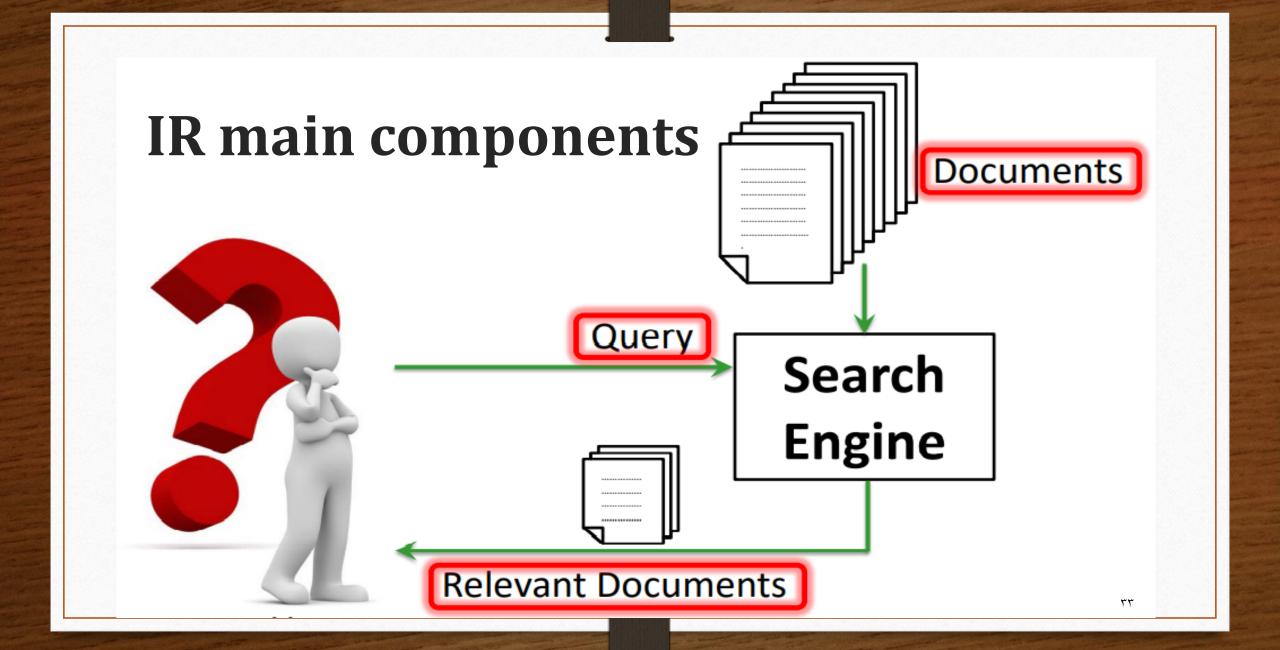
## IR, basic form



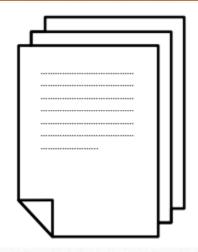
### Two main issues in IR

About 293,000,000 results (0.79 seconds)

- جودة البحث وهي مقدار جودة النتائج المعادة (هل هي ذات صلة) Effectiveness
  - need to find relevant documents
  - needle in a haystack
  - very different from relational DBs (SQL)
- سرعة البحث أو سرعة استجابة محرك البحث وسرعة الرد Efficiency
  - need to find them quickly
  - vast quantities of data (10's billions pages)
  - thousands queries per second (Google, ~40,000)
  - data constantly changes, need to keep up



## الوثائق Documents



- Document = the element to be retrieved
  - Unstructured nature عادة تكون غير مهيكلة
  - Unique ID لها رقم فريد
  - عددها كبير وتدعى مدونة أو مجموعة N documents --> Collection
- web-pages, emails, book, page, sentence, tweets
- photos, videos, musical pieces, code
- answers to questions
- product descriptions, advertisements
- people

## الاستعلامات Queries

- لدى المستخدم مهمة يريد البحث عنها نعبر عنها ب حاجة المعلومات وهي موجودة داخل عقل المستخدم، أعبر عن هذه الحاجة داخل صندوق البحث باستعلام
  - الاستعلام ليس هو Information need وإنما هي تمثيل لحاجة المعلومات
- Free text to express user's information need
- Same information need can be described by different queries مثلاً للبحث عن الخصوصية في تطبيقات الدردشة
  - Are chatting Apps secure? هل تطبيقات الدردشة آمنة
  - Live chat protection حماية الدردشة الحية
  - Breaches in online chat الخروقات في الدردشة عبر الانترنت
- Same query can represent different information needs
  - Apple
  - Jaguar







## Queries - different forms

• هناك العديد من الأشكال لكتابة الاستعلام:

- Web search e.g.: keywords, narrative ...
- Image search e.g. keywords, sample image
- QA e.g. question
- Music search e.g. humming a tune
- Filtering/recommendation e.g. user's interest/history
- Scholar search e.g. structured (author, title ..)
- Advanced search
  - #wsyn(0.9 #field (title, #phrase (homer, simpson)) 0.7 #and (#> (pagerank, 3), #ow3 (homer, simpson)) 0.4 #passage (homer, simpson, dan, castellaneta))

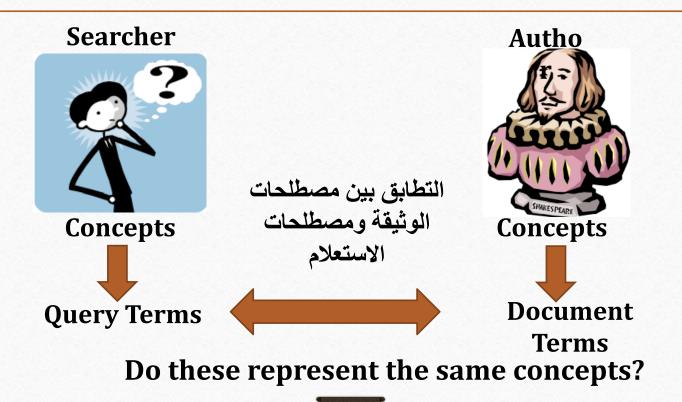
# الموائمة Relevance

- في المستوى التجريدي، مهمة محركات البحث إعادة نتائج (وثائق) توافق استعلام معطى:
- does item d match query q? ... or ...
- is item d relevant to query q?
- Relevance is a tricky notion
  - will the user like it / click on it?
  - will it help the user achieve a task? (satisfy information need)
  - is it novel (not redundant)?
- Relevance and similarity يتحول موضوع الموائمة إلى قياس درجة التشابه
  - i.e. d,q share similar "meaning" بين الوثيقة والاستعلام
  - about the same topic / subject / issue التشابه بالموضوع

# Information Need/Query/Relevance

- Information need
  - Topic about which the user desires to know more
  - In the user's mind!
- Query
  - What the user conveys to the computer
  - Considered one representation of the information need
- Relevance
  - Document having a value with respect to the information need
  - i.e., a document is relevant if it satisfies the information need

# A central problem in search



# What is the challenge in relevance?

- No clear semantics!
  - "William Shakespeare"
  - Author history's? list of plays? a play by him?
- Inherent ambiguity of language!
  - polysemy: "Apple", "Jaguar"
- Relevance is highly subjective!
  - Rel: yes/no, Rel: perfect/excellent/good/fair/bad

# Information Retrieval (IR) is ...

Finding material (usually documents) of an unstructured nature (usually text) that satisfies an information need from within large collections

### IR vs DB vs NLP vs ML

IR == DB?

# IR is NOT "DB"

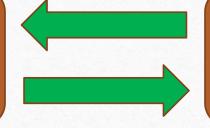
	DB	IR
What we're retrieving	Structured data. Clear semantics based on a formal model.	Mostly unstructured. Free text with some metadata.
Queries we're posing	Formally-defined (relational algebra, SQL). Unambiguous.	Free text ("natural language"), Boolean
Results we get	Exact (always "correct")	Imprecise (need to measure effectiveness)
Interaction with system	One-shot queries	Interaction is important

#### IR vs DB vs NLP vs ML

IR == NLP?

#### IR is NOT "NLP"!

معالجة اللغات الطبيعية (NLP)



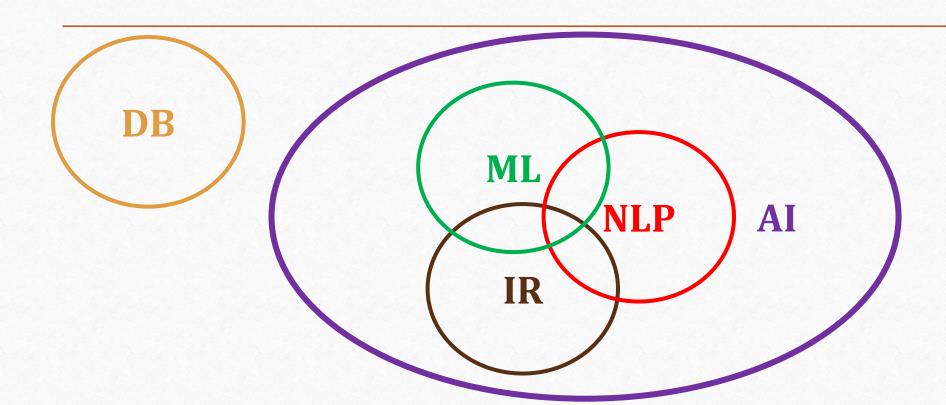
استرجاع المعلومات (IR)

"IR makes NLP useful. NLP makes IR interesting."
- Jimmy Lin

### IR vs DB vs NLP vs ML

IR == ML?

## AI



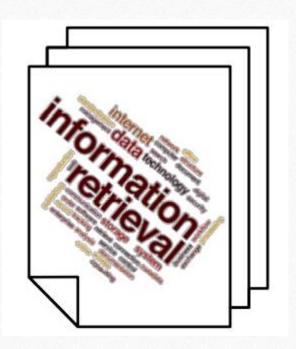
# خارطة الطريق لليوم Today's Roadmap

- Introduction to IR
- How IR "sees" documents?
- Boolean retrieval



# How IR "sees" documents?





# **Bag-of-Words trick**

- Can you guess what this is about:
  - per is salary hour £5,594 Neymar's
    - Neymar's salary per hour is £5,594
  - obesity French is of full cause and fat fries
    - French fries is full of fat and cause obesity
- Main idea: Re-ordering doesn't destroy the topic
  - individual words are "building blocks"
  - "bag" of words: a "composition" of "meanings"

# Simplest: Bag-of-Words trick

- Most search engines use BOW
  - treat documents and queries as bags of words
- A "bag" is a set with repetitions
  - match = "degree of overlap" between d, q
- Retrieval models
  - statistical models (functions): usually use words as features
  - decide which documents most likely to be relevant
- BOW makes these models tractable (and also effective!) دقة في البحث (وسرعة)

### **Retrieval Models**

**BOOLEAN RETRIVAL** 



# What's the Simplest IR System?

- Given a collection of documents and a "free text" query
- How can we get some search results in a simple way?
- grep-like: a "sequential scan"
- Simple but ...
  - very inefficient
- Is it effective?

How can we make it more effective AND efficient?



# The goal is

جعل طريقة البحث أكثر فاعلية more effective وأكثر سرعة more efficient

#### **Boolean Retrieval Model**

- يهمنا في النموذج طريقة تمثيل الاستعلام والوثائق
  - الاستعلام يكتب كتعبير بولياني
  - الوثائق تمثل بمجموعة من BOW
- Queries: Users express queries as a Boolean expression
  - AND, OR, NOT
  - Can be arbitrarily nested
  - Ex. query: information AND retrieval AND NOT technology
- Documents: Views each document as a "bag" of words
- Return only documents that satisfy the Boolean query.

#### Exercise

- Build a Term-Document Incidence Matrix
  - Which term appears in which document
  - Rows are terms
  - Columns are documents
- Given example collection:
  - d1: He likes to play, he likes to eat
  - d2: He likes to eat, and eat, and eat
  - d3: The thing he likes to eat is apple
  - d4: The apple he likes to eat is red
  - d5: He likes to play, and eat red apple

	d1	d2	d3	d4	d5
he	1	1	1	1	1
likes	1	1	1	1	1
to	1	1	1	1	1
play	1	0	0	0	1
eat	1	1	1	1	1
and	0	1	0	0	1
the	0	0	1	1	0
thing	0	0	1	0	0
is	0	0	1	1	0
apple	0	0	1	1	1
red	0	0	0	1	1

#### Term-Document Incidence Matrix

#### **Documents**

	d1	d2	d3	d4	d5
he	1	1	1	1	1
likes	1	1	1	1	1
to	1	1	1	1	1
play	1	0	0	0	1
eat	1	1	1	1	1
and	0	1	0	0	1
the	0	0	1	1	0
thing	0	0	1	0	0
is	0	0	1	1	0
apple	0	0	1	1	1
red	0	0	0	1	1

**TERMS** 

1 if document contains term, 0 otherwise

\_

#### Term-Document Incidence Matrix

	d1	d2	d3	d4	d5	
he	1	1	1	1	1	
likes	1	1	1	1	1	
to	1	1	1	1	1	
play	1	0	0	0	1	
eat	1		1	1	1	
and	0	1	0	0	1	
the	0	0	1	1	0	
thing	0	0	1	0	0	
is	0	0	1	1	0	
apple	0	0	1	1	1	
red	0	0	0	1	1	

Query: play AND eat AND NOT apple

**Apply on rows: 10001 AND 11111 AND !(00111) = 10000** 

#### **Boolean Retrieval Model**

- Any given query divides the collection into two sets:
  - retrieved (matching)
  - not-retrieved (not matching)
- Returns a set of documents that "exactly" satisfy the query (Boolean expression)
  - Called "Exact-Match" retrieval
- Used?
  - Many search systems still in-use are Boolean
  - e.g., Email, library catalog, Mac OS X Spotlight, legal search

# Google?

#### Advanced Search

Find pages with		To do this in the search box.
all these words:		Type the important words: tri-colour rat terrier
this exact word or phrase:		Put exact words in quotes: "rat terrier"
any of these words:		Type OR between all the words you want: miniature OR standard
none of these words:		Put a minus sign just before words that you don't want: -rodent, -"Jack Russell"
numbers ranging from:	to	Put two full stops between the numbers and add a unit of measurement: 1035 kg, £300£500, 20102011

# Bigger Collections

- Consider N = 1 million documents, each with about 1000 words. عدد كبير من الوثائق
- Say there are M = 500K distinct terms among these. في كل وثيقة عدد كبير من المصطلحات المميزة
- 500K x 1M matrix has half-a-trillion 0's and 1's. عدد كبير جدا من الأصفار والواحدات
- But it has no more than one billion 1's. عدد قليل من الواحدات
- matrix is extremely sparse. المصفوفة ستكون مبعثرة

What's a better representation?



Will Term-Doc Incidence Matrix "works" for large collections?

If not, how can we make retrieval efficient?

How documents are preprocessed?

Is "Car" == "Cars"?

# Thank you for Attention Afaf Al Shalaby, Ph.D.

